2025.08.11

제작자 | 이마가

교육용 RAG 에이전트 서비스 구축 제안

AI 기술 확보 및 활용을 통한 업무 생산성 향상과 전사 AX 가속화

목차

01

제안 배경

- 교육 환경에서 AI 활용 필수화
-기존 질의응답·자료검색 한계
-로컬 LLM·RAG로비용 절감 및 유연성 확보

02

제안 목적

-PDF 기반 지능형 학습 도우미 구축
-맞춤형 프롬프트·역할기반 답변 지원
-학습 효율성과 사용자 경험 향상

03

핵심 기술

-FastAPI 백엔드 & GPT 스타일 UI
-HuggingFace 로컬 LLM(Qwen/Gemma)
-FAISS 벡터 검색·PyMuPDF텍스트 추출
-다양한 프롬프팅 기법(Zero-shot 등)

04

전략 및 아키텍처

-업로드→추출→벡터화→검색→응답 파이프라인
-모드별 프롬프트 빌더 적용
-클라우드 배포 확장성 확보

05

비용 및 기대효과

- 오픈소스·로컬LLM 활용으로 API 비용 절감
-문서 검색·요약시간 단축
-맞춤형 학습 지원 및 생산성 향상

06

추진 일정 계획

-1주차: 기획·요구사항정의
-2주차: 기본 기능 구현
-3주차: 프롬프트 튜닝·UX개선
-4주차: 클라우드 배포·최종테스트

01

제안배경

프로젝트의 제안배경에 대해 설명한다.

제안 배경



프로젝트 필요성

- 교육·업무현장에서 PDF 기반 문서 검색과 질의응답 자동화 수요 급증
- 방대한 학습 자료를 신속하게 처리·검색할수 있는 AI 에이전트 필요
- 기존 수작업 중심의 문서 분석·검색업무를 AI로 대체해 생산성 향상



현재 문제점

- 기존 챗봇은 학습 자료 반영이 느리고, 컨텍스트 기반 답변 품질이 낮음
- OpenAI API 의존 시 비용 부담 및 개인정보 유출 위험 존재
- 한국어 프롬프트와 로컬 환경 최적화 부족으로 사용자 경험 저하



해결 방향

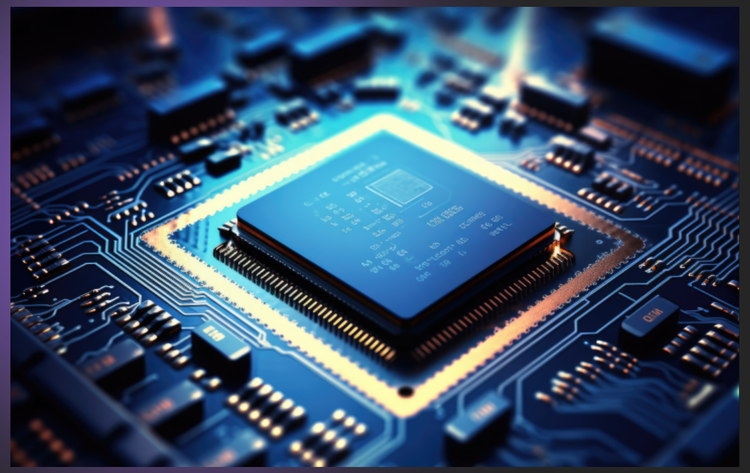
- 로컬 LLM(Qwen 등)과 RAG(Retrieval-Augmented Generation) 구조 결합
- PDF 업로드 → 자동 청킹 → 벡터 인덱싱 → 컨텍스트 기반 답변
- 다양한 프롬프트 모드(Default, Few-shot, Role, CoT)로 답변 품질 극대화
- 웹 UI를 통해 직관적이고 친근한 챗봇 인터페이스 제공

02

핵심기술 및 기능

프로젝트의 핵심기술 및 기능에 대해 설명한다.

핵심 기술



데이터 수집·전처리기술

- PDF 파일에서 텍스트 추출(pdf_utils.py)
- 청크 사이즈·오버랩설정 기반 텍스트 분할로 문맥 보존
- 벡터 인덱싱 전처리를 위한 불필요 문자·공백 제거

벡터 검색 기반 RAG 기술

- FAISS 또는 로컬 벡터스토어를 활용한 문서 임베딩 및 검색
- 사용자 질문과 유사도 검색을 통해 최적의 컨텍스트 반환
- 검색 결과 상위 K개 문서를 답변 생성에 반영

로컬 LLM 활용 및 프롬프트 엔지니어링

- Qwen/Qwen2.5-0.5B-Instruct 모델 로컬 실행
-프롬프트 모드별 답변 전략 (default / few_shot / role / cot)
- 한국어에 최적화된 친절한 답변 스타일 + 컨텍스트 기반 응답

웹 UI 및 사용자 인터랙션

- FastAPI + Jinja2Templates 기반의 GPT 스타일 대화 UI
- PDF 업로드, 인덱스 초기화, 답변 모드 전환 기능 제공
-실시간 채팅과 문서 검색 기능 통합

핵심 기능

PDF 업로드 및 텍스트 추출

- 사용자가 PDF 업로드 시 pdf_utils.py에서 자동 텍스트 추출
- 텍스트를 문맥 손실 없이 청크 단위로 분할 (청크 크기·오버랩 적용)

벡터 인덱스 생성 및 검색

- 추출된 청크를 벡터 임베딩으로 변환 후 로컬 벡터스토어 저장

- 질문 입력 시 유사도 검색으로 관련 문서 Top-K 반환

다중 프롬프트 모드 지원

- default : 기본 질의응답
- few_shot : 예시 기반 학습형 답변
- role : ‘친절한 튜터’ 역할로 비유와 요약 제공
- cot : 단계적 추론(Chain of Thought) 방식 응답

한국어 최적화 LLM 응답

- Qwen 0.5B Instruct 모델 기반 한국어 응답 최적화
- 컨텍스트 기반으로만 답변, 정보 부족 시 "모름" 처리

웹 기반 인터랙션

- FastAPI + Jinja2Templates를 이용한 대화형 웹 UI
- PDF 업로드, 인덱스 초기화, 모드 전환, 실시간 응답 가능

03

전략 및 목표 서비스

프로젝트의 전략 및 목표 서비스에 대해 설명한다.

전략



로컬·클라우드병행 아키텍처

- 개발 단계에서는 로컬 환경에서 RAG(검색+생성) 구조 테스트
- 추후 AWS/GCP/Azure로 확장 가능하도록 구조 모듈화

확장 가능한 벡터 스토어 설계

- 현재는 로컬 파일 저장 구조
- 이후 Milvus, Pinecone 등 대규모 데이터 검색 엔진으로 교체 가능

오픈소스 기반 비용 절감

- 개발 단계에서는 로컬 환경에서 RAG(검색+생성) 구조 테스트
- 추후 AWS/GCP/Azure로 확장 가능하도록 구조 모듈화

프롬프트 튜닝을 통한 성능 개선

- 현재는 로컬 파일 저장 구조
- 이후 Milvus, Pinecone 등 대규모 데이터 검색 엔진으로 교체 가능

목표 서비스 구성도

문서 기반 AI Q&A 플랫폼

PDF, 매뉴얼, 보고서 등 업로드 후 질문·답변제공

클라우드 기반 상시 서비스

API 형태로 타 서비스·챗봇과연동 가능

교육용 학습 도우미

학생·연구자가참고문헌, 강의자료를 업로드하고 질의응답 가능

다국어 확장

현재 한국어 최적화 → 영어·중국어지원까지 확장

기업 지식관리 시스템(KMS)

내부 매뉴얼·정책문서검색 및 자동 요약

04

기대효과

프로젝트의 기대효과에 대해 설명한다.

기대효과



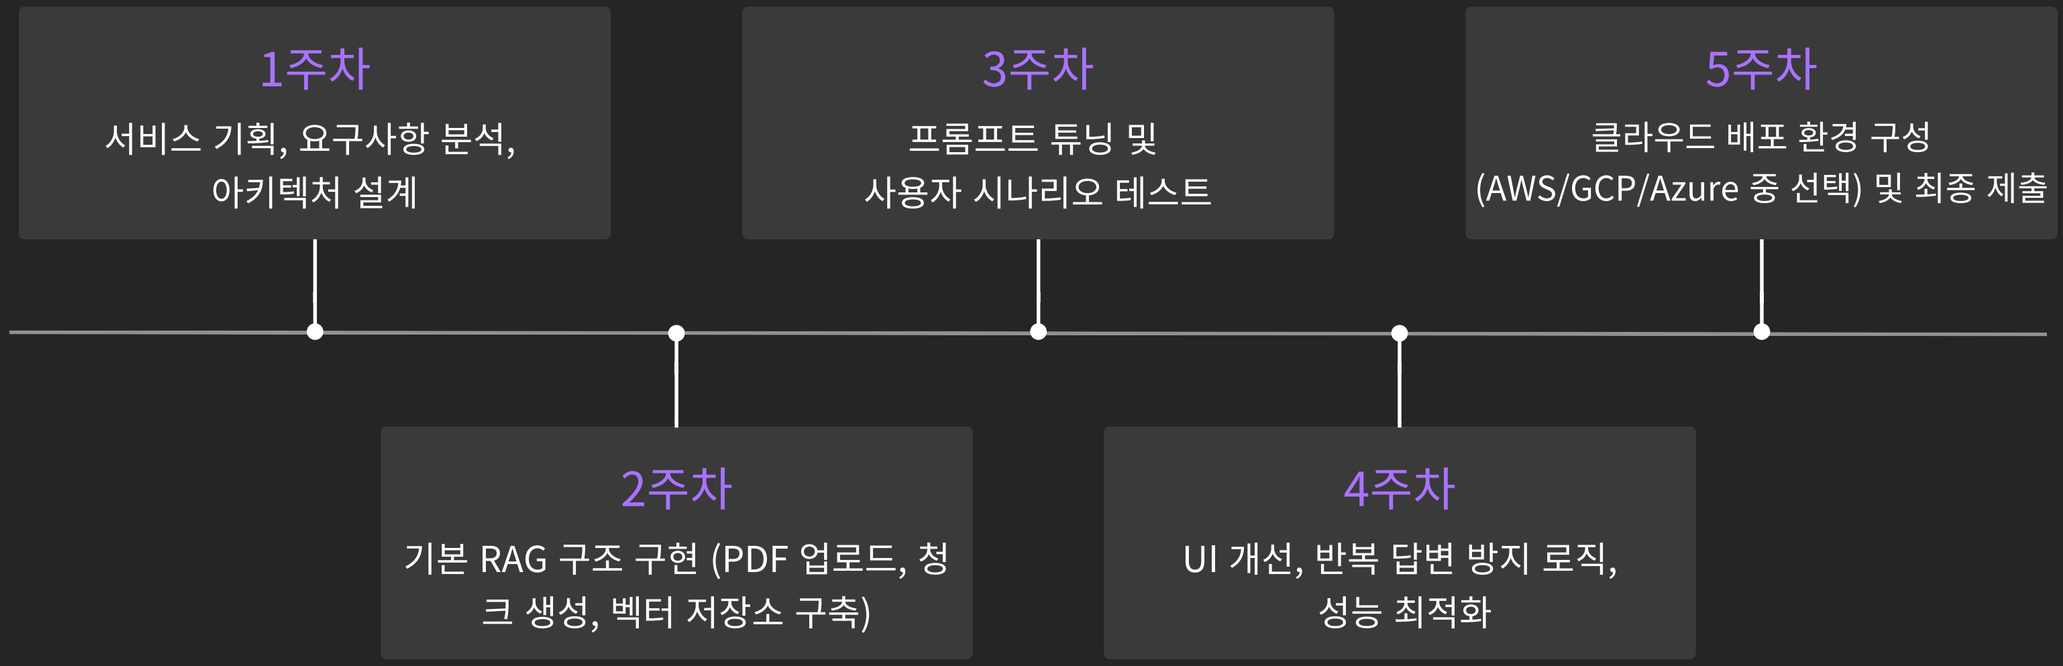
이번 프로젝트는 로컬 LLM과 오픈소스 기반 RAG 구조를 활용하여 직관적인 스타일의 UI와 한국어 최적화 응답을 제공함으로써, 사용자가 모호한 질문이나 엣지 케이스 상황에서도 안정적인 대화 경험을 할 수 있도록 합니다. 이를 통해 문서 내 필요한 정보를 신속하게 검색·요약하고,반복적인 자료 탐색 업무를 자동화하여 업무 효율성을 높이며, API 호출 비용 절감과 같은 비용 효율성을 확보합니다. 또한, 벡터스토어·프롬프트엔진·UI의모듈화 구조를 통해 교육, 기업 지식관리, 고객지원 챗봇 등 다양한 도메인으로 확장 가능성을 제공합니다.

05

프로젝트 기간

프로젝트의 전체 기간에 대해 설명한다.

프로젝트기간


1주차
서비스 기획, 요구사항 분석,
아키텍처 설계
2주차
기본 RAG 구조 구현 (PDF 업로드, 청
크 생성, 벡터 저장소 구축)
3주차
프롬프트 튜닝 및
사용자 시나리오 테스트
4주차
UI 개선, 반복 답변 방지 로직,
성능 최적화
5주차
클라우드 배포 환경 구성
(AWS/GCP/Azure 중 선택) 및 최종 제출

감사합니다.

교육용 RAG 에이전트 서비스 구축 제안